# Hazem Ilahi

**Élève ingénieur en Data Science & IA — Machine Learning | MLOps | LLM / RAG**

Tunis, Tunisie | +216 97 111 410 | hazem.ilahi@esprit.tn | linkedin.com/in/hazem-ilahi-016a7a315 | github.com/Dyaus2 | dyaus2.github.io

**Recherche un stage de fin d'études (PFE) de 6 mois à partir de janvier/février 2027 — mobilité internationale**

*Stage obligatoire du cursus — convention de stage tripartite signée par ESPRIT*

## PROFIL

Élève ingénieur en dernière année à ESPRIT (diplôme prévu en 2027), spécialité Science des Données & IA, avec une expérience pratique en machine learning, MLOps et systèmes LLM/RAG. Lors de mon dernier stage, j'ai conçu la couche de détection par ML d'un framework d'investigation numérique : détection d'anomalies et classifieur calibré par gradient boosting, portant la couverture des étapes d'attaque de 18 % à 84 % à 1 % de faux positifs, avec une chaîne de réentraînement hebdomadaire (champion/challenger, surveillance de la dérive, retour arrière automatique). Je recherche un stage appliqué en data science / ML engineering : détection d'anomalies, analyse prédictive, applications LLM/RAG, MLOps, prévision.

## FORMATION

**ESPRIT — École Supérieure Privée d'Ingénierie et de Technologies** 2023 – 2027 (diplôme prévu)

*Cycle ingénieur, Science des Données & Intelligence Artificielle — dernière année ; stage de fin d'études obligatoire de 6 mois (PFE) à partir de janvier/février 2027* *Ariana, Tunisie*

**IPEIT — Institut Préparatoire aux Études d'Ingénieurs de Tunis** 2020 – 2023

*Cycle préparatoire, Physique-Chimie* *Montfleury, Tunisie*

## EXPÉRIENCE PROFESSIONNELLE

**Stagiaire Machine Learning — NEXT STEP IT (département SOC)** Juillet 2026 – Septembre 2026

*ATOR DFIR — couche de détection de menaces par ML et chaîne MLOps* *Charguia 1, Tunisie*

- Couverture des étapes d'attaque sur un corpus public d'émulation d'adversaire portée de 18 % (règles Sigma seules) à 84 % (règles + ML) à 1 % de faux positifs ; 135 des 168 étapes manquées par les règles récupérées.
- Conception et intégration de la couche ML d'ATOR DFIR, framework d'investigation numérique et de chasse aux menaces sur postes Windows/Linux, au-dessus d'un moteur de règles YARA/Sigma développé par l'équipe sécurité.
- Classifieur de vraisemblance de menace (gradient boosting par histogrammes, calibration de Platt) : PR-AUC de 0,927 contre 0,278 pour les règles, erreur de calibration de 1,6 %, validation croisée à 5 plis groupée par capture.
- Détection d'anomalies non supervisée (Isolation Forest, 300 arbres) : 23 des 25 premiers signalements du benchmark sont de vraies étapes d'attaque ; classifieur de tactique MITRE ATT&CK avec seuil de confiance (79,7 % de précision).
- Jeu d'entraînement constitué à partir de 115 captures d'attaques publiques (Empire, Covenant, Mimikatz, Metasploit) converties par ETL vers le schéma du framework et labellisées par filiation de processus ; 110 variables comportementales par processus, calculées par un code unique partagé entre entraînement et production.
- Chaîne MLOps hebdomadaire : snapshot, ETL, réentraînement, 14 critères de qualité hors ligne, essai silencieux champion/challenger de 7 jours sur le trafic réel, déploiement atomique avec contrôle canari, retour arrière automatique, surveillance de la dérive (PSI) et protection du réentraînement contre l'empoisonnement de la référence.
- Intégration : 10 endpoints REST et page de chasse aux menaces pour analystes SOC (priorités P1–P4, verdicts) ; plus de 500 tests automatisés, dont des tests d'injection de pannes garantissant qu'une défaillance ML n'interrompt jamais la détection par règles.

*Stack : Python 3.13, scikit-learn, pandas, NumPy, SQLite, FastAPI, Jinja2, pytest, Git*

**Stagiaire Développeur — NEXT STEP IT** Juillet 2025 – Septembre 2025

*Plateforme web de génération de rapports SOC (stage en binôme)* *Charguia 1, Tunisie*

- Conception et développement en binôme d'une plateforme web Python/Django destinée aux analystes SOC, avec une interface UI/UX intuitive.
- Automatisation de la génération des rapports SOC, en remplacement de la rédaction manuelle répétitive ; préparation de la solution en vue d'un futur déploiement.

*Stack : Python, Django, HTML/CSS, Git*

## PROJETS

**TurboWatch — Copilote de maintenance prédictive pour turboréacteurs** 2026

*Projet personnel — démo : dyaus2.github.io/turbowatch · code : github.com/Dyaus2/turbowatch*

- Prédiction de la durée de vie résiduelle (RUL) sur les données turboréacteurs NASA C-MAPSS : gradient boosting avec bande P10–P90 et CNN 1D (PyTorch) sur des variables causales normalisées par régime, partagées entre entraînement et production ; RMSE RUL sur le test de 15,5 cycles (CNN) / 16,3 (GBM), moyenne sur 5 graines, découpage par moteur.
- Risque calibré et politique d'alarme k parmi n réglée sur une matrice de coûts : 97 % des pannes du jeu de test détectées avec une avance médiane de 36 cycles, à 2 % de fausses alarmes ; explication SHAP de chaque prédiction.
- Copilote RAG de maintenance sur documents FAA/NASA (bge-small + BM25, RRF, reranking par cross-encoder) : réponses citées, refus hors périmètre ; bon passage classé premier sur 26 questions de test sur 26, y compris en exécution entièrement dans le navigateur (transformers.js).
- MLOps et livraison : MLflow, détection de dérive PSI avec réentraînement champion/challenger (RMSE test FD003 20,7 → 15,0), API FastAPI + tableau de bord React/TypeScript avec rejeu en direct, Docker, CI GitHub Actions.

*Stack : Python, scikit-learn, PyTorch, SHAP, MLflow, FastAPI, sentence-transformers, React, TypeScript, Docker*

**UnderHood (Garage Augmenté) — Assistant multi-agents de pré-diagnostic automobile (RAG)** 2026 – 2027

*Projet d'équipe, ESPRIT — responsable de la base de connaissances et de la couche de recherche*

- Corpus : 7 collecteurs Python reprenables : 2 019 manuels du propriétaire (≈ 697 000 pages, 26 marques, 73 % de sources officielles), couvrant 54 des 56 modèles prioritaires du marché tunisien. Déduplication SHA-256, OCR Tesseract (≈ 18 500 pages), 364 familles de modèles, index Qdrant de 101 417 passages.
- Recherche : expansion de requêtes FR / EN / derja tunisienne et réécriture par LLM, recherche hybride BGE-M3 + BM25 (RRF), filtre marque/modèle/année, reranking par cross-encoder et consultation exacte de 9 533 codes OBD-II. Le tout est exposé en service FastAPI à l'agent de diagnostic (LangGraph).
- Évaluation : ablation sur 40 questions (hit@5, MRR, jugement LLM en double aveugle) : le filtre véhicule fait passer le taux de bonnes réponses dans le bon manuel de 0 % à 72 % (MRR 0,63).

*Stack : Python, Qdrant, BGE-M3, BM25, FastAPI, LangGraph, PyMuPDF, Tesseract*

**DressMe — Assistant de mode personnel intelligent pour le marché tunisien** 2026 – 2027

*Projet d'équipe (7 personnes, Advanced Data Science Project), ESPRIT — de la conception au prototype fonctionnel (API + application mobile)*

- Représentation du style : benchmark d'encodeurs sur Polyvore (152 785 articles, IC bootstrap à 95 %). Choix de Qwen3-VL-Embedding-2B, aussi précis que le 8B mais 3,7× plus rapide. « Fashion DNA » apprise par un Set Transformer entraîné en contrastif (InfoNCE).
- Tenues personnalisées : tête de compatibilité par paire de catégories (AUC 0,852 contre 0,830 pour le cosinus seul). Génération par beam search selon la météo et l'occasion. Personnalisation par Thompson sampling avec prior de population, évaluée sur 40 personas simulées pendant 60 jours.
- Vision et IA générative : segmentation SAM 3 et reconnaissance des vêtements sur photo (96,6 % de précision en remplissage automatique). Essayage virtuel par diffusion (Qwen Image Edit via ComfyUI). Styliste LLM local (Qwen 9B) dont chaque phrase est vérifiée contre les faits : 199 réponses sur 200 ancrées.
- IA explicable et marché : contributions exactes de chaque critère au score ; cartes d'occlusion évaluées en fidélité (courbes deletion/insertion) ; concepts affichés seulement au-delà d'une AUC de 0,85 ; prix de seconde main prédits par LightGBM quantile et calibration conforme (couverture 80,0 % sur 423 k annonces), expliqués par TreeSHAP.

*Stack : Python, PyTorch, FastAPI, LightGBM, llama.cpp, React Native (Expo)*

**Kadastra — Plateforme d'intelligence immobilière basée sur l'IA** 2026

*Projet d'équipe (Data Crunchers), ESPRIT — méthodologie Microsoft TDSP*

- Pipeline de bout en bout pour le marché immobilier tunisien : collecte de ≈ 26 000 annonces (Mubawab, Tayara), estimation de prix par XGBoost, génération de contrats et de scénarios d'investissement.
- Suppression d'une fuite de données dans les variables du modèle ; calage des constantes financières sur la législation tunisienne et les taux de la BCT ; déploiement full-stack FastAPI, Django, React et Docker.

**Show, Attend and Tell — Génération automatique de légendes d'images (vision + NLP)** 2026

*Projet de Deep Learning — PyTorch, Flickr8k*

- Reproduction du modèle encodeur-décodeur à attention (CNN + LSTM), puis extensions : encodeur ViT, reranking du beam search par CLIP et fine-tuning de BLIP ; évaluation BLEU et visualisation des cartes d'attention.

**Analyse de séries temporelles — Dépenses de construction aux États-Unis** 2026

*Projet de modélisation statistique en R*

- Analyse des dépenses de construction résidentielle (U.S. Census Bureau) en trois phases : analyse graphique, ajustement déterministe (tendances polynomiales), modélisation ARIMA/SARIMA avec diagnostics et prévisions.

## COMPÉTENCES TECHNIQUES

**Langages:** Python, R, SQL, C/C++, Java, PHP
**ML / DL:** scikit-learn, XGBoost, PyTorch, TensorFlow, Keras ; détection d'anomalies, classification, calibration, validation croisée groupée ; vision par ordinateur (CNN, ViT, CLIP, BLIP) ; séries temporelles (ARIMA/SARIMA)
**LLM / RAG / NLP:** pipelines RAG, Qdrant, embeddings BGE-M3, BM25, recherche hybride, reranking par cross-encoder, évaluation hit@k / MRR, Transformers
**MLOps:** réentraînement automatisé, registre de modèles, MLflow, déploiement champion/challenger, surveillance de la dérive (PSI), critères de qualité, déploiement canari et retour arrière, pytest
**Data:** pandas, NumPy, ETL, web scraping, OCR (Tesseract), SQLite, Power BI, Tableau
**Cloud & déploiement:** AWS (Cloud Foundations), Docker, Docker Compose, FastAPI, Django, Flask, Spring Boot, Symfony, API REST, n8n, Git
**Méthodologies:** Microsoft TDSP, CRISP-DM, Design Thinking, Agile/Scrum

## CERTIFICATIONS

- AWS Cloud Foundations — Amazon Web Services (badge, novembre 2026) — vérifier sur Credly
- Fundamentals of Deep Learning — NVIDIA (2026)
- Applications of AI for Anomaly Detection — NVIDIA (2026)
- Building Transformer-Based Natural Language Processing Applications — NVIDIA (2026)
- CCNA 2 : Switching, Routing, and Wireless Essentials (SRWE) — Cisco Networking Academy (2025)

## LANGUES

Arabe : langue maternelle | Français : courant (niveau avancé, usage professionnel) | Anglais : courant